Министерство науки и высшего образования РФ
Пензенский государственный университет
Кафедра «Вычислительная техника»

Отчёт

по лабораторной работе №8
по курсу «Технологии глубоких нейронных сетей»
на тему «Локальное развёртывание LLM»

Выполнил:
студент группы 23ВВИ2
Юров Д.М.

Принял:
Митрохин М.А.

Пенза 2026

Цель работы: изучить применение большой языковой модели для обработки текстовых данных и получения ответов на вопросы по содержимому текстового файла.

Задание:

1. Открыть среду Google Colab.
2. Открыть файл LLM_local.ipynb.
3. Прочитать комментарии и выполнить приведённый в ноутбуке код.
4. С помощью развернутой LLM проанализировать файл ENG_article.txt. Найти в тексте ответы на следующие вопросы:
   - В каком году была обозначена проблема взрывающихся градиентов.
   - Кто в 1891 году разработал метод уничтожающей производной.
   - Кто предложил цепное правило дифференцирования и в каком году.
5. Сохранить созданные промпты и ответы LLM.
6. Загрузить в репозиторий код, промпты и ответы LLM.

Ход выполнения:

1. Открыл среду Google Colab, выгрузил на Google Drive файлы проекта.

2. Прочитал комментарии и выполнил приведенный в ноутбуке код.

3. Выполнил задание 1 (рис. 1-3).

4. Сохранил созданные промпты и ответы LLM.

5. Загрузил в репозиторий GitHub код, промпт и ответы LLM.

```
[20]
0s
file_negr = '/content/drive/MyDrive/Colab Notebooks/ENG_article.txt'
try:
    with open(file_negr, 'r', encoding='utf-8') as f:
        data = f.read().replace('\n', ' ')
except UnicodeDecodeError:
    with open(file_negr, 'r', encoding='cp1251') as f:
        data = f.read().replace('\n', ' ')


print("len:", len(data))
print("words:", len(data.split()))
print(data[:300])

len: 8291
words: 1157
Wikipedia https://en.m.wikipedia.org/wiki/Neural_network_(machine_learning) Neural network (machine learning)
```

Рисунок 1 - первый блок (загрузка данных)

```
[23]
0s
prompt_system = (
    "Ты анализируешь текстовый файл. "
    "Отвечай только на основе текста, который дан пользователем. "
    "Не придумывай факты. "
    "Если в тексте нет точного ответа или формулировка вопроса не совпадает с текстом, прямо укажи это. "
    "Ответ дай на русском языке."
)

prompt_user = (
    "Проанализируй текст файла ENG_article.txt и найди ответы на вопросы:\n"
    "1. В каком году была обозначена проблема взрывающихся градиентов?\n"
    "2. Кто в 1891 году разработал метод уничтожающей производной?\n"
    "3. Кто предложил цепное правило дифференцирования и в каком году?\n\n"
    "Важно:\n"
    "- отвечай строго по содержимому текста;\n"
    "Текст:\n" + data
)

messages = [
    {"role": "system", "content": prompt_system},
    {"role": "user", "content": prompt_user}
]

text = tokenizer.apply_chat_template(
    messages,
    tokenize=False,
    add_generation_prompt=True
)

print(text[:500])

<|im_start|>system
Ты анализируешь текстовый файл. Отвечай только на основе текста, который дан пользователем. Не придумывай факты.
<|im_start|>user
Проанализируй текст файла ENG_article.txt и найди ответы на вопросы:
1. В каком году была обозначена проблема взрывающихся градиентов?
2. Кто в 1891 году разработал метод уничтожающей производной?
3. Кто предложил
```

Рисунок 2 - второй блок (промпты)

```
[24]
2m
task_inputs = tokenizer([text], return_tensors="pt").to(model.device)

task_generated_ids = model.generate(
    **task_inputs,
    max_new_tokens=512,
    temperature=0.2
)

task_generated_ids_trimmed = [
    output_ids[len(input_ids):]
    for input_ids, output_ids in zip(task_inputs.input_ids, task_generated_ids)
]

task_response = tokenizer.batch_decode(
    task_generated_ids_trimmed,
    skip_special_tokens=True
)[0]

print(task_response)

1. В каком году была обозначена проблема взрывающихся градиентов?
Ответ: В тексте указано, что проблема взрывающихся градиентов была идентифицирована в 1991 году в дипломной работе Сеппа Хохрейтера.

2. Кто в 1891 году разработал метод уничтожающей производной?
Ответ: В тексте нет информации о том, кто разработал метод уничтожающей производной в 1891 году. Упоминается только, что терминология "back-propagating errors" была введена в 1962 году Розенблаттом.

3. Кто предложил цепное правило дифференцирования и в каком году?
Ответ: Цепное правило дифференцирования было получено Готфридом Вильхельмом Лейбницем в 1673 году.
```

Рисунок 3 - третий блок (ответ LLM)

Вывод: в ходе выполнения лабораторной работы изучил применение большой языковой модели для обработки текстовых данных и получения ответов на вопросы по содержимому текстового файла.

Репозиторий: https://github.com/danya-purple02/TGNS/tree/master/lab8